

Instalación de Herramientas

Autor

Martín Vladimir Alonso Sierra Galvis

Gestión de Datos, Maestría en Ciencia de Datos
Pontificia Universidad Javeriana Cali

Versión 1.0
Santiago de Cali, febrero de 2023

Tabla de contenido

Consideraciones	2
Anaconda	3
¿Qué es Anaconda?	3
Instalando Anaconda	3
Jupyter Notebook	6
Hola Mundo en Python	8
Módulos pandas, numpy y matplotlib	10
Sobre los ambientes virtuales de Anaconda	10

Consideraciones

Este documento está dirigido a todos aquellos alumnos que deseen instalar las herramientas de la presente unidad en sus dispositivos personales. Es importante tener en cuenta que la plataforma de Python Anaconda y el editor Jupyter Notebook se encuentran instalados en las máquinas virtuales que provee la Universidad para el desarrollo de las actividades de la Maestría.

Anaconda

¿Qué es Anaconda?

Anaconda es una plataforma open source de Python. Está enfocada a la Ciencia de Datos y la Inteligencia Artificial, específicamente el Machine Learning, por lo que cuenta con un número considerable de módulos de Python encargados de realizar procesos relacionados con estas áreas del conocimiento. Entre los módulos más conocidos se encuentran **numpy**, **pandas**, **matplotlib**, **scikit learn** y **tensorflow**. Adicionalmente, Anaconda cuenta con un tablero de control llamado Anaconda Navigator desde donde podremos administrar ambientes virtuales de Python e instalar software especializado adicional como Jupyter Notebook o Spyder, IDE de Python para trabajar Ciencia de Datos.

Instalando Anaconda

En esta unidad y en la siguiente trabajaremos con el lenguaje de programación Python. Específicamente, usaremos dos módulos: **pandas** para realizar análisis, limpieza y preparación de datos; y **matplotlib** para visualización de datos. Además, para un mejor entendimiento y desarrollo tanto de los ejemplos como del Caso propuesto, utilizaremos la herramienta Jupyter Notebook. Todo esto lo podemos obtener instalando Anaconda. El instalador de este software lo podemos encontrar en el siguiente enlace.

<https://www.anaconda.com/>

Apenas al ingresar podemos ver un botón de descarga de nombre Download. Algo interesante es que el sitio web de Anaconda detecta automáticamente el sistema operativo de nuestro dispositivo y nos muestra el tipo, versión del instalador y su peso. Para esta guía en particular, el instalador es para Windows de 64 bits, trae Python 3.9 y pesa 621 MB. Si el sitio web no detecta correctamente el sistema operativo, podemos seleccionar uno específico en la sección **Get Additional Installers**, como se muestra a continuación.




For Windows

Python 3.9 • 64-Bit Graphical Installer • 621 MB

Get Additional Installers




Una vez descargado, nos dirigimos al directorio Descargas del sistema operativo y buscamos el archivo de aplicación de nombre Anaconda3-2022.10-Windows-86_64 y damos doble click en ella. Aparecerá la siguiente ventana.




Damos click en Next y, en la siguiente vista, damos click en el botón I Agree para indicar que aceptamos los términos y condiciones del acuerdo de licencia. A continuación, el instalador nos muestra dos opciones de instalación: **Just Me** y **All Users**. La selección de esta opción depende de si queremos tener disponible Anaconda para todos los usuarios que creamos en el sistema. Para

el caso particular de esta guía, seleccionamos Just Me y damos click en Next. La vista siguiente es importante pues nos muestra la ruta de instalación, además del espacio que ocupará en disco duro, aproximadamente 3.7 GB.



Aquí podemos configurar la ruta de instalación a nuestro gusto mediante el botón Browse... aunque se recomienda dejar la ruta por defecto. Damos click en Next. La última vista nos presenta nuevamente dos opciones: **Add Anaconda3 to my PATH** y **Register Anaconda3 as my default Python 3.x**. Si seleccionamos la primera opción, el instalador agrega la ruta de la carpeta bin de Anaconda al Path de las variables de entorno del sistema. Esto podría sernos útil en caso de querer administrar todas la funcionalidades de Anaconda desde el Símbolo del Sistema de Windows, es decir, desde la línea de comandos. Ahora bien, nosotros no necesitamos esto pues trabajaremos con Anaconda Navigator. La segunda opción es interesante pues, como nos dice el instalador, al seleccionarla, la versión de Python de Anaconda se vuelve predeterminada en el sistema operativo. Esto significa que todos aquellos programas que requieran Python como, por ejemplo, PyCharm (IDE de Python de JetBrains), usarán la versión de Anaconda.




Siguiendo la recomendación del instalador, seleccionamos únicamente la segunda opción. Finalmente, damos click Install para que comience el proceso de instalación, mismo que puede tardar varios minutos.

Jupyter Notebook


Jupyter Notebook es un editor de texto y de código que funciona con tecnología web. Esto quiere decir que cuando ejecutemos la aplicación, esta se abrirá en un navegador web, específicamente, en el navegador web que se encuentre configurado como predeterminado en el sistema operativo de nuestro dispositivo. Esta herramienta nos permitirá escribir código de Python y ejecutarlo de una manera muy simple para ver el resultado del algoritmo. Además, podremos escribir texto a modo de títulos, subtítulos y párrafos usando el formato Markdown. Todo esto mediante el concepto de celdas. En cada celda podremos escribir código o texto markdown y Jupyter nos dará la opción de ejecutarlas por separado o todas en conjunto. Lo interesante de Anaconda es que en su instalación base ya cuenta con diversas herramientas disponibles para utilizar, entre ellas Jupyter Notebook. Veámoslo a continuación.

Cuando el proceso de instalación de Anaconda haya terminado, buscamos en nuestro dispositivo la aplicación Anaconda Navigator. La ejecutamos y,

pasados unos segundos, se nos abrirá el panel de control de la plataforma Anaconda, mismo que se muestra a continuación.



Como su nombre lo indica, en este panel de control podremos administrar y controlar diversas herramientas y módulos de Anaconda que nos facilitaran el trabajo al momento de sumergirnos en el mundo de la preparación y limpieza de datos, el análisis de datos y el Machine Learning. Y una de dichas herramientas de Jupyter. Como podemos observar, al momento de ejecutar Anaconda Navigator, la opción seleccionada por defecto en el panel izquierdo es Home. En el panel de la derecha veremos que el contenido de Home son un conjunto de aplicativos instalados automáticamente por Anaconda; entre ellos se encuentra Jupyter Notebook, mismo que podremos abrir utilizando el botón azul **Launch** que se encuentra en la parte inferior del Card o celda correspondiente a Jupyter (podremos identificar la celda correcta gracias a que cada una cuenta con el logo de su herramienta concreta). Al dar click en el botón Launch, y pasados unos segundos, se debe abrir automáticamente el navegador web predeterminado del sistema operativo con la vista inicial de la aplicación, como se muestra en la siguiente imagen.




Aquí Jupyter nos está listando los directorios ubicados en la ruta del usuario del sistema operativo. Por ejemplo: esta ruta, en Windows, es `C:\Users\[nombre del usuario]\`. Se recomienda crear un directorio específico para trabajar con los cuadernos de Jupyter. Para el caso de esta guía, dicho directorio se ubica en la ruta `Desarrollo/Docencia/Jupyter Notebook`.


Hola Mundo en Python

Python es un lenguaje de programación interpretado de alto nivel que permite la implementación de software de diversa índole. Esto quiere decir que con Python se pueden crear desde programas simples de terminal hasta programas mucho más complejos como videojuegos. En nuestro caso, lo usaremos para implementar algoritmos que nos permitan realizar diversos procesos de Gestión de Datos en el contexto de la Ciencia de Datos. En particular, en este módulo, trabajaremos todo lo relacionado con análisis, limpieza, preparación y visualización de datos y, gracias al alto nivel del lenguaje, será, para nosotros, relativamente sencillo entender el código que estemos implementando. Ahora bien, al enfrentarnos a un nuevo lenguaje de programación, uno de los primeros pasos para probarlo y familiarizarnos con

la sintaxis del mismo es ejecutar el famoso **Hola Mundo**. Para esto, lo que haremos es acceder al directorio que destinamos para trabajar con los cuadernos de Jupyter y, seguidamente, damos click en el botón New, ubicado en la parte superior derecha de la vista, justo por encima de la barra donde aparece la ruta en la que estamos ubicados. Cuando damos click en dicho botón se despliega un menú en el que debemos seleccionar la opción **Python 3 (ipykernel)**. A continuación se abrirá una pestaña en el navegador cuyo contenido corresponde a un nuevo cuaderno de Jupyter con una primera celda.



La celda que Jupyter activa por defecto está lista para ejecutar código Python, tal como se especifica en la barra de herramientas superior, donde aparece la palabra **Code**. Escribimos la sentencia **print("Hola Mundo")** en la celda y la ejecutamos mediante el botón **Run**, obteniendo el siguiente resultado.




Con estos sencillos pasos hemos ejecutado un código Python en Jupyter y hemos comprobado que estamos listos para trabajar con la herramienta.

Módulos pandas, numpy y matplotlib

Los módulos pandas, numpy y matplotlib son paquetes de Python que necesitaremos en las unidades del presente módulo. El módulo pandas nos ayudará a manipular datos de un dataset para limpiarlos y corregir posibles errores en ellos; por su parte, numpy nos brindará una forma avanzada de trabajar con datos de tipo numérico; finalmente, matplotlib nos permitirá visualizar los datos mediante gráficas estadísticas. La instalación base de Anaconda trae por defecto estos módulos, por lo que no requerimos realizar ningún paso adicional para usarlos más que codificar la sentencia **import** en el script de Python donde los vamos a requerir (p. ej.: **import** pandas).

Sobre los ambientes virtuales de Anaconda

Durante el proceso de instalación de Anaconda habremos notado que la plataforma, a su vez, instala un gran número de herramientas automáticamente. Es importante entender que estas se instalan en un directorio de anaconda, específicamente, el ubicado en anaconda3/Scripts y no directamente en el disco C:\, como sucede cuando instalamos otros programas. La razón de esto es que Anaconda utiliza lo que se conoce como un **ambiente virtual**. Un ambiente virtual de Anaconda es, a grandes rasgos, un contenedor de módulos de Python. La ventaja de estos ambientes es poder administrar distintas versiones de los módulos de Python que necesitemos utilizar en diferentes proyectos. De esta forma se evitan problemas de compatibilidad al tratar de instalar las diferentes versiones de un mismo módulo en el sistema. Cuando Anaconda realiza su instalación, crea automáticamente un ambiente virtual de nombre **base** donde alberga todas las herramientas pertenecientes a su plataforma. Por simplicidad usaremos este ambiente para realizar los ejemplos y ejercicios del presente módulo. Aun así es bueno saber que Anaconda, por medio de Anaconda Navigator, nos brinda la posibilidad de crear nuestros propios ambientes virtuales. Lo único que debemos hacer es ingresar a la sección **Environments** del panel izquierdo. Una vez allí, en el panel central, podremos observar el ambiente virtual base y en el panel derecho veremos todos los módulos instalados en dicho ambiente. Es importante no modificar ni eliminar este ambiente. Para crear un ambiente nuevo debemos dar click en el botón **Create** del panel central e ingresar el nombre del ambiente y la versión de Python a utilizar, tal como se muestra en la siguiente imagen.



Debemos tener en cuenta que el nuevo ambiente contendrá los módulos básicos para que el mismo funcione de manera correcta por lo que, muy seguramente, tendremos que instalar los módulos jupyter, pandas, numpy y matplotlib. Si tomamos la decisión de crear y utilizar un ambiente diferente a base y necesitamos instalar los módulos antes mencionados, podemos hacerlo dando click en el botón verde de play en la celda del ambiente y, seguidamente, dando click en la opción **Open Terminal**. Esto abrirá una línea de comandos con el ambiente virtual activo. Para instalar los módulos usamos el comando **conda** así.

```
conda install jupyter pandas numpy matplotlib
```

Cuando nos pregunte si deseamos proceder con la instalación de los módulos y sus respectivas dependencias le indicamos que sí. Una vez el proceso haya terminado, tendremos jupyter, pandas, numpy y matplotlib disponibles para usar con Python.