

Hadoop y Spark


Motores de Procesamiento Distribuido

Martín Vladimir Alonso Sierra Galvis




Pontificia Universidad
JAVERIANA
Cali

Contexto



Big Data

Grandes volúmenes de datos que, por su cantidad, no se pueden almacenar, procesar y analizar con los métodos convencionales, por lo que necesitan Motores de Procesamiento Distribuido



Motor de Procesamiento Distribuido

Herramienta que permite la escritura de código sin tener que preocuparse por la complejidad de la infraestructura necesaria para hacer procesamiento distribuido.

1. Consumir masivamente datos.
2. Filtrar y consultar a bases de datos.
3. Almacenar y exportar grandes volúmenes de datos.
4. Programar y monitorear tareas

Algunos motores


1. Apache Hadoop.
2. Apache Spark.
3. Apache Storm.
4. ElasticSearch.
5. Lumify.

Existen motores, como Apache Hive y Apache Pig, que actúan como capas sobre otros motores.



Apache Hadoop


Historia



¿Qué es Apache Hadoop?

Framework que se encarga de administrar el almacenamiento distribuido de grandes volúmenes de datos y de su procesamiento en paralelo. Conjunto de programas usados como base para la ejecución de diversas operaciones enfocadas a Big Data.

Arquitectura HDFS + MapReduce → ejecución de tareas en su entorno de trabajo.




La arquitectura HDFS

Basado en el Google File System, Hadoop Distributed File System es el sistema de archivos mediante el que Hadoop realiza almacenamiento de grandes volúmenes de datos de forma distribuida.

Divide los datos de archivos muy grandes en pequeños bloques o **chunks** y los distribuye en los nodos de un clúster, replicándolos en el proceso.




Esquema HDFS



Arquitectura de Hadoop

Dos componentes principales:
Namenode y Datanode.

Se basa en el concepto de **master-slave** donde un nodo maestro administra y controla varios nodos esclavos.



Namenode

Divide los datos en distintos bloques.

Distribuye y replica los bloques en los Datanodes.

Administra tareas de lectura y procesamiento.

Monitorea los nodos.

Datanode

Almacena los bloques de datos.

Ejecuta las tareas sobre los datos.

Envía **heartbeats** al nodo maestro.

Pero... ¿por qué HDFS?

La importancia de HDFS radica en la posibilidad de usar commodity hardware para la implementación de la estructura de almacenamiento, lo que conlleva a:

1. Fácil acceso a equipos de hardware.
2. Menores costos de implementación.
3. Alta escalabilidad.

Pero... ¿por qué HDFS?

Además, HDFS permite el almacenamiento de datos estructurados, semiestructurados y no estructurados.

Finalmente, aumenta la seguridad y la disponibilidad de los datos gracias a las réplicas en los Datanodes.


Procesamiento con MapReduce

Modelo de programación que usa las funciones `map` y `reduce` para el procesamiento distribuido de los datos. Se enfoca en la ejecución distribuida de tareas en múltiples nodos del clúster.

Tres tareas principales: Map, Shuffle y Reduce.



Esquema MapReduce




Map, Shuffle y Reduce


1. **Map:** proceso que se realiza sobre los chunks y genera una pareja **key-value**.
2. **Shuffle:** agrupa todos los datos iguales en nuevos chunks y los ordena.
3. **Reduce:** ejecuta una función de agregación para realizar un conteo de los datos ordenados. Resultado final.

¿Y por qué MapReduce?

MapReduce permite llevar el procesamiento a los Datanodes.



Esquema tradicional de procesamiento



Esquema Map-Reduce de procesamiento

¿Qué soluciona Apache Hadoop?

1. Gestión de grandes volúmenes de datos.
2. Gestión de diferentes tipos y fuentes de datos.
3. Gracias a HDFS, Hadoop permite realizar análisis de Big Data a menores costos.
4. Con MapReduce, Hadoop permite el procesamiento de Big Data en un menor tiempo de ejecución.

¿Quiénes usan Apache Hadoop?

1. **Chevron** (empresa petrolera): mejorar su servicio para ayudar a los consumidores a ahorrar dinero en las facturas de energía.
2. **AOL** (servicios de internet): generar estadísticas y análisis de comportamiento.
3. **eBay** (comercio electrónico): optimización de su motor de búsqueda.
4. **Tinder** (red social de citas): análisis de comportamiento para crear encuentros personalizados.
5. **Skybox Imaging** (): almacenamiento y procesamiento de imágenes para identificar patrones en los cambios geográficos.



Apache Spark

Historia




¿Qué es Apache Spark?

Framework open source que actúa como un motor de procesamiento para almacenar y procesar datos en tiempo real a través de varios clústers de computadoras.




Componentes de Apache Spark



Arquitectura de Apache Spark

Spark utiliza una arquitectura basada en el concepto master-slave.



Procesamiento en Apache Spark

1. **SparkContext**: punto de entrada a las funcionalidades de Spark.
2. **RDD o Resilient Distributed Datasets**: colección de objetos donde se cargan los datos para su procesamiento. Las operaciones se realizan sobre estos de forma paralela.
 - a. Transformaciones: **map**, **filter**, **join**.
 - b. Acciones: **reduce**, **count**.

Procesamiento en Apache Spark II

1. **DataFrames:** representación de datos en filas y columnas. Se crean por medio de DataFrame API. Se cargan en los RDD para su procesamiento.
2. **DAG o Directed Acyclic Graph:** grafo usado por Spark para definir las operaciones como un flujo lógico. Los vértices son los RDD y los bordes son las transformaciones sobre los datos.

¿Para qué Apache Spark?

1. Spark mantiene los beneficios de MapReduce como la escalabilidad y la distribución de tareas, mejorando su eficiencia y facilidad de uso.
2. Spark ejecuta operaciones en memoria, mejora en la velocidad de ejecución.
3. Además del procesamiento **batch** de MapReduce, Spark agrega procesamiento **stream**, dando así soporte para respuestas en tiempo real.


Apache Hadoop

Arquitectura master-slave.

Procesamiento batch. Procesa por periodos de tiempo.

Modelo MapReduce.

Trabaja usando el disco duro.




Apache Spark

Arquitectura master-slave.

Procesamiento batch y stream.
Procesa en tiempo real.

Directed Acyclic Graph.

Trabaja usando la memoria RAM y la caché.



¿Quiénes usan Apache Spark?

1. **JPMorgan Chase & Co** (empresa financiera): identificación de transacciones fraudulentas, análisis de movimientos bancarios de los clientes para sugerir ofertas, identificaciones de patrones para tomar decisiones de inversión.
2. **Alibaba** (comercio electrónico): análisis de transacciones para recomendar productos a los usuarios.
3. **IQVIA** (sector salud): identificar problemas de salud en pacientes y realizar diagnósticos a partir de historias clínicas.
4. **Netflix y Riot Games** (entretenimiento): mostrar anuncios relevantes a los usuarios basados en videos que ven y likes.

¡Muchas gracias!

Referencias I

1. Bernard Marr & Co. Intelligent Business Performance. *What is Hadoop*. [En línea]: disponible en <https://www.bernardmarr.com/default.asp?contentID=1080>. [Accedido en 2020].
2. edureka! *What is Hadoop | Hadoop Tutorial for Beginners | Edureka*. Abril de 2017. [En línea]: disponible en <https://www.youtube.com/watch?v=n3qnsVFNEIU>. [Accedido en 2020].
3. ProjectPro. *Hadoop Explained: How does Hadoop work and how to use it?* [En línea]: disponible en <https://www.dezyre.com/article/hadoop-explained-how-does-hadoop-work-and-how-to-use-it-/237>. [Accedido en 2020].
4. Simplilearn. *What is Hadoop | What is Big Data & Hadoop | Introduction to Hadoop | Hadoop Tutorial | Simplilearn*. Febrero de 2019. [En línea]: disponible en <https://www.youtube.com/watch?v=iANBytZ26MI>. [Accedido en 2020].

Referencias II

1. Luminousmen. *Spark core concepts explained*. Abril de 2020. [En línea]: disponible en <https://luminousmen.com/post/spark-core-concepts-explained>. [Accedido en 2020].
2. McDonald, C. *Spark 101: What is It, What it Does, and Why it Matters*. Octubre de 2018. [En línea]: disponible en <https://mapr.com/blog/spark-101-what-it-what-it-does-and-why-it-matters/>. [Accedido en 2020].
3. Simplilearn. *Spark Tutorial For Beginners | Big Data Spark Tutorial | Apache Spark | Simplilearn*. Junio de 2017. [En línea]: disponible en <https://www.youtube.com/watch?v=QaoJNXW6SQo>. [Accedido en 2020].
4. Simplilearn. *What Is Apache Spark? | Introduction To Apache Spark | Apache Spark Tutorial | Simplilearn*. Agosto de 2019. [En línea]: disponible en <https://www.youtube.com/watch?v=znBa13Earms>. [Accedido en 2020].

Referencias de logos

Todos los logos fueron encontrados a través del buscador de Google, opción imágenes:

1. Hadoop Elephant. Imagen en línea obtenida de <https://co.pinterest.com/pin/296393219208327456/>. [Accedido en 2020].
2. Hadoop HDFS. Imagen en línea obtenida de <http://www.genericclass.com/hadoop/an-introduction-to-hdfs/>. [Accedido en 2020].
3. Hadoop MapReduce. Imagen en línea obtenida de <http://www.errequerre.es/mapreduce-y-hadoop>. [Accedido en 2020].
4. Spark Star: Imagen en línea obtenida de <https://geekytheory.com/apache-spark-que-es-y-como-funciona>. [Accedido en 2020].