

MÓDULO 2 - UNIDAD 1

Introducción al aprendizaje supervisado

El aprendizaje automático, en inglés conocido como *machine learning*, es un área de la inteligencia artificial que está muy activa en la actualidad. Gracias a los avances en el desarrollo y adaptación de nuevas técnicas se ha logrado aumentar dramáticamente la calidad con la que se pueden resolver algunas tareas de clasificación y predicción automática como: el reconocimiento de objetos en imágenes, el reconocimiento de habla, la clasificación de imágenes médicas con propósitos de apoyo al diagnóstico, la construcción de perfiles de familias de proteínas, la clasificación automática de cartas de correo postal de acuerdo a su sitio de destino, la toma de decisiones de inversión de manera automática, entre otros muchos ejemplos.

El aprendizaje automático comprende técnicas que tienen diversos objetivos:

- El aprendizaje supervisado busca predecir el valor de un atributo de salida a partir de los valores de un conjunto de atributos de entrada previamente establecidos. Este tipo de aprendizaje es útil para desarrollar tareas de clasificación o regresión que permitan realizar una predicción.
- El aprendizaje no supervisado busca relaciones naturales entre los datos de un conjunto, identificando conglomerados, en inglés llamados *clúster*, que ayuden a comprender la estructura de un conjunto de datos. Estas técnicas se usan principalmente en tareas de tipo exploratorio, o como un paso previo en el posterior procesamiento de un conjunto de datos demasiado grande para ser procesado completo. Indirectamente pueden servir para hacer clasificación.
- El aprendizaje por refuerzo busca maximizar la ganancia acumulada durante un proceso de toma de decisiones. Estas técnicas se enfocan en el efecto combinado de un conjunto de decisiones sobre el logro de un objetivo planteado como una función a maximizar.





El aprendizaje supervisado

Las técnicas de aprendizaje supervisado son las que vamos a estudiar con detalle en este documento. Formalmente, el aprendizaje supervisado se define a partir de un conjunto de atributos de entrada $X_1, X_2, \dots, X_n$ y un conjunto de atributos de salida $Y_1, Y_2, \dots, Y_m$. Cada atributo tiene un dominio de valores posibles, que pueden ser discreto o continuo, numérico o categórico, ordenado o secuencial. El problema del aprendizaje supervisado consiste en desarrollar un modelo f , que permita computar una estimación de los valores de los atributos de salida a partir del valor de los atributos de entrada:

$$\hat{Y}_1, \hat{Y}_2, \dots, \hat{Y}_n = f(X_1, X_2, \dots, X_n).$$

Existen diversas estrategias dentro de este enfoque. Algunas tienen su origen en la estadística, otras en la optimización y otras son modelos bioinspirados. Algunas de las técnicas más conocidas y utilizadas son:

- **K-vecinos más cercanos**
- **Árbol de decisión**
- **Bosque aleatorio (*random forest* en inglés)**
- **Máquina de vectores de soporte**
- **Perceptrones multicapa**
- **Redes profundas**

A continuación, se presenta una explicación introductoria de cada una de las técnicas de aprendizaje supervisado previamente enumeradas.

Técnica de los k-vecinos más cercanos

Esta técnica se caracteriza porque no construye un modelo a partir de los datos de entrenamiento que le permita posteriormente hacer la clasificación de un ejemplo nuevo en una de las categorías existentes. En vez de construir el modelo, la técnica utiliza los datos disponibles como representantes de las clases a las que pertenecen. Cuando llega un nuevo ejemplo, se buscan los representantes más similares al dato nuevo y se define la categoría a la que pertenece aplicando una función como por ejemplo la moda o la media sobre las categorías de los vecinos más cercanos. El número de vecinos que se van a consultar para tomar la decisión se denota con la **letra K** que aparece en el nombre de la técnica. **El parámetro K** debe ser definido por el usuario y generalmente esto se hace de manera experimental (ejecutando el método con varios valores de K e identificando cuál de ellos permite obtener una predicción más acertada). **Los valores usuales de K** son enteros impares pequeños.

Para identificar cuáles son los ejemplos más similares al dato nuevo se necesita usar una medida de distancia o una de similitud. Existe una variedad de medidas que se pueden usar, siendo algunas: la distancia euclidiana, la distancia de Manhattan, la distancia de Minkowsky, la similitud del coseno, entre otras.



Árbol de decisión

Esta técnica realiza la clasificación de un ejemplo nuevo haciendo repetidas preguntas sobre los valores de los atributos, las cuales surgen al avanzar por una rama del árbol previamente construido a partir de los ejemplos conocidos. Existen varias maneras de construir el árbol, pero básicamente ellas lo que hacen es ubicar en los nodos internos del árbol una pregunta sobre el valor de un atributo de entrada, las ramas que salen del nodo correspondiente a las posibles respuestas para esa pregunta.

Por ejemplo:

Si el nodo pregunta por el estado civil de una persona, las ramas que salen de él corresponderán a los valores posibles: soltero, casado, separado, etc. El número de posibles respuestas debe ser finito y estar definido previamente.

Otro ejemplo:

Si el nodo interno pregunta si la temperatura de una habitación es superior o inferior a 20 grados centígrados, del nodo saldrán dos ramas, una correspondiente a la respuesta **SI** y otra para la respuesta **NO**. Dentro de una misma rama del árbol cada nodo interno consulta por el valor de un atributo de entrada, en tanto que el nodo final (la hoja) corresponde a una predicción sobre el valor del atributo de salida.

La clave para construir el árbol que permitirá hacer la clasificación es seleccionar el orden en que se consulta el valor de los atributos, de manera que se pueda hacer la predicción consultando la menor cantidad posible de ellos. Es decir, se debe preferir preguntar primero por el atributo que permita una mejor diferenciación de los ejemplos en términos del atributo a predecir. Existen varias funciones que sirven para evaluar los atributos e identificar aquel por el cual preguntar primero. Una función es la ganancia de información, cuyo cálculo se basa en medir la entropía del conjunto de datos antes y después de separarlo con respecto a un atributo de entrada. Otra función que se usa con frecuencia es GINI. A continuación, se definen estas funciones:



Bosque aleatorio (random forest en inglés)

El bosque aleatorio corresponde a una extensión del árbol de decisión para usarlo al interior de una técnica de ensamble. Esto quiere decir que ya no se construye un único árbol que produzca la clasificación, sino que se entrena una diversidad de árboles a partir de cuyas predicciones se consolida una predicción final. Cada árbol se entrena sobre un conjunto de datos extraído aleatoriamente del conjunto original, pero con repetición, es decir, que pueden quedar ejemplos repetidos. Adicionalmente, cada árbol se entrena sobre un subconjunto de los atributos de entrada elegido aleatoriamente. De esta manera los árboles no sólo quedan diferentes, sino que son complementarios.

El usuario de la técnica debe estimar los siguientes parámetros: número de árboles a generar, rango de variación del número de atributos a considerar, entre otros.

Máquina de vectores de soporte

Este método traza una frontera lineal para separar los datos de una clasificación binaria. La técnica se basa en detectar la región de separación entre las dos clases, llamada margen, y ubica la frontera en el medio de dicho margen. De los datos de entrenamiento en realidad sólo se usan aquellos que se encuentran en la periferia de clase, es decir, cerca al margen, los que se conocen como vectores de soporte, dándole nombre a la técnica. El método para definir cuál es la frontera de decisión consiste en resolver un problema de optimización cuadrática con restricciones. La frontera obtenida es óptima, dado el conjunto de datos de entrenamiento.

Perceptrones multicapa

Esta técnica se inspira en un modelo simplificado de la forma como se conectan entre sí las neuronas en el cerebro, y cómo interactúan para responder a un estímulo. El elemento básico, llamado unidad, representa una neurona y se define a través de un conjunto de señales de entrada, que provienen de otras neuronas, y una función de activación no lineal que permite calcular el valor de salida de la unidad. Las unidades se conectan a través de conexiones que tienen asociado un peso, representado por un número real.

Cuando la unidad se activa calcula su entrada neta que es la sumatoria del producto de los valores que le entran de otras unidades por el peso de las conexiones a través de las cuales le llegan dichos valores. La función de activación tiene como parámetro la entrada neta y



produce como resultado el valor de salida de la unidad, que, a su vez, será propagado hacia otras unidades que estén conectadas con ésta.

En un perceptrón multicapa las unidades se organizan en capas, y la propagación viaja de una capa a la siguiente de forma ordenada, iniciando en la entrada de la red y terminando en la capa de salida. El aprendizaje del perceptrón multicapa es el proceso mediante el cual se modifican los pesos de las conexiones de manera que se minimice el error en la salida de la red. La herramienta matemática que permite realizar este aprendizaje es la técnica del gradiente descendente y el algoritmo que la implementa se conoce como back-propagation.

Redes profundas

Las redes profundas son la evolución de los perceptrones multicapa. En esta evolución se conciben arquitecturas de mayor tamaño (más capas y más unidades por capa), también se flexibilizan algunos aspectos de la arquitectura: se permite variedad en las funciones de activación, se consideran en una misma red diversos tipos de capas con funciones diferentes. También se observa que en las redes profundas la inicialización de la red es un tema más elaborado, pues se permite iniciar el aprendizaje en un estado específico, no forzar a iniciar en un estado aleatorio como se hacía en las versiones previas.

Existen varios modelos que se consideran redes profundas, de ellos los más conocidos a día de hoy son las redes convolucionales y las redes recurrentes LSTM. Cada modelo tiene sus propias características y debe ser analizado en forma independiente.

