

Hipótesis de solución — Telco Customer Churn

Módulo 2 · Aprendizaje Automático — Entrega final de hipótesis

Buen día profesor,

Le comparto la propuesta final de hipótesis para el problema de fuga de clientes en telecomunicaciones (Telco Customer Churn). Antes de plantear las hipótesis hice un EDA completo sobre los 7,043 registros; el notebook con el código y las gráficas está en el siguiente enlace:

https://drive.google.com/file/d/1_DhomB9cbWNgdN8B0y65Sste4kHMy-lc/view?usp=sharing

Formulación matemática

El problema se plantea como aprendizaje supervisado: dado un conjunto de atributos de entrada $X_1, X_2, \dots, X_n$ de un cliente, se busca un modelo f que estime el atributo de salida:


$$\hat{Y} = f(X_1, X_2, \dots, X_n)$$

Aquí $\hat{Y} \in \{0, 1\}$ es la variable Churn (1 = cancela, 0 = permanece), y $X_1, \dots, X_n$ son los atributos del cliente después de codificar las categóricas con one-hot: antigüedad, cargo mensual, cargo total, tipo de contrato, método de pago, servicios contratados, entre otros. Cada una de las cuatro hipótesis siguientes propone una forma distinta de construir f , y la formulación matemática específica se muestra junto a cada una.


Lo que encontré en el EDA

La clase está desbalanceada: 73.5% de los clientes permanece y 26.5% cancela. TotalCharges tenía 11 valores vacíos, todos de clientes con tenure = 0, así que los imputé en 0. Esa misma variable correlaciona 0.83 con tenure y 0.65 con MonthlyCharges, hay que tenerlo presente en modelos lineales. Las columnas "No internet service" y "No phone service" son redundantes al 100% con InternetService y PhoneService, las colapsé a "No".


Dos variables se destacan sobre las demás: el tipo de contrato (42.7% de churn en mes a mes, contra apenas 2.8% en contratos de dos años) y el método de pago (45.3% de churn con Electronic check, contra 15-19% en pagos automáticos). Tener servicios como OnlineSecurity o TechSupport también reduce bastante el churn.




Tenure, MonthlyCharges y TotalCharges: sin outliers extremos, rangos consistentes con lo esperado.




Distribución de la clase Churn: 5,174 No vs. 1,869 Yes (73.5% / 26.5%).




Correlación entre variables numéricas: $\text{TotalCharges} \approx f(\text{tenure}, \text{MonthlyCharges})$.



Antigüedad y cargo mensual por Churn: solapamiento amplio entre clases, no hay frontera lineal obvia.



Tasa de Churn por tipo de contrato: 42.7% (mes a mes) vs. 2.8% (dos años).



Tasa de Churn por método de pago: 45.3% en Electronic check vs. 15-19% en el resto.

Hipótesis 1 — Regresión Logística

La uso como modelo base porque es interpretable: los coeficientes se leen directo como razones de posibilidades, útil para justificar campañas de retención frente al negocio. Como TotalCharges está correlacionado con tenure y MonthlyCharges, la saco del conjunto de entrada para no meter colinealidad. Las categóricas van con one-hot, y para el desbalance uso `class_weight='balanced'` o SMOTE sobre el set de entrenamiento.

Formulación:

$$P(\text{Churn}=1 \mid X) = \sigma(w \cdot X + b) = 1 / (1 + e^{-(w \cdot X + b)})$$

$w = (w_1, \dots, w_n)$ son los pesos aprendidos para cada atributo y b el intercepto. Se predice $\text{Churn}=1$ si $P > 0.5$, o el umbral que se ajuste según el balance recall/precision.

Hipótesis 2 — Random Forest

Random Forest no necesita que estandarice nada y maneja bien la mezcla de categóricas y numéricas. Lo elijo porque el churn no depende de una sola variable sino de combinaciones (contrato + método de pago + servicios contratados), y un ensamble de árboles captura mejor esas interacciones que un modelo lineal. Igual que en el modelo anterior, pondero las clases en el entrenamiento.

Formulación:

$$\hat{Y} = \text{moda}\{T_1(X), T_2(X), \dots, T_B(X)\}$$

Cada T_b es un árbol de decisión entrenado sobre una muestra bootstrap de los datos y un subconjunto aleatorio de atributos. La predicción final es la clase mayoritaria entre los B árboles (o el promedio de las probabilidades que entrega cada uno).

Hipótesis 3 — SVM con kernel RBF

Los boxplots de tenure y MonthlyCharges por Churn muestran bastante traslape entre las dos clases (medianas de 10 vs. 38 meses, 80 vs. 65 USD, con rangos que se cruzan), así que una frontera lineal simple no va a alcanzar. Por eso planteo SVM con kernel RBF y margen suave. Requiere todo numérico, entonces one-hot para las categóricas y StandardScaler para las numéricas. C y gamma los ajusto por grid search con validación cruzada estratificada.

Formulación:

$$f(X) = \text{sign}(\sum_i \alpha_i y_i K(X_i, X) + b), \text{ con } K(X_i, X) = \exp(-\gamma \|X_i - X\|^2)$$

Los α_i son los multiplicadores de Lagrange del problema dual (solo son distintos de cero para los vectores de soporte), y γ controla qué tan localizada es la influencia de cada punto sobre la frontera.

Hipótesis 4 — Perceptrón Multicapa (MLP)

La reducción de churn que se ve al tener OnlineSecurity, TechSupport o los servicios de streaming activos sugiere relaciones no lineales entre servicios que un modelo lineal no capta bien. Para esto planteo un MLP: 16 variables categóricas a one-hot, las tres numéricas estandarizadas (tenure y TotalCharges están en escalas muy distintas). Con solo 26.5% de ejemplos de churn, aplico SMOTE-NC únicamente sobre el set de entrenamiento, y controlo el sobreajuste con early stopping.

Formulación:

$$\hat{Y} = \sigma(W_2 \cdot h(W_1 X + b_1) + b_2)$$

h es una función de activación no lineal (ReLU) en la capa oculta y σ es la sigmoide en la capa de salida. W_1 , W_2 , b_1 , b_2 son los pesos y sesgos que se ajustan por descenso de gradiente (back-propagation).

En las cuatro valido con validación cruzada estratificada y un set de prueba aparte, priorizando recall y F1 sobre la clase Churn por encima del accuracy solo, dado el desbalance.

Quedo atento a sus comentarios. Gracias por la oportunidad de entregar la hipótesis por este medio.