

ANÁLISIS DE DATOS ABIERTOS CON HERRAMIENTAS OPEN SOURCE

(Parte 1)



¿QUÉ ES?

El análisis de datos es un proceso sistemático que permite **transformar información en bruto en conocimiento valioso**, facilitando:

- Toma de decisiones informadas.
- Identificación de patrones y tendencias.
- Comprensión profunda de conjuntos de datos complejos.



PRIMEROS PASOS DEL PROCESO INTEGRAL DE ANÁLISIS DE DATOS



1. Preparación y depuración de datos



Objetivo: transformar datos en bruto en conjuntos limpios y estructurados.



Ejemplos de herramientas



OpenRefine

COMPLETAMENTE GRATUITA

Limpieza y transformación de datos. Ofrece una interfaz gráfica e intuitiva que es multiplataforma (requiere Java). Detecta:

- Duplicidades
- Datos incompletos
- Inconsistencias estructurales



Talend Open Studio

GRATIS EN SU VERSIÓN BÁSICA

Herramienta ETL (Extraer, Transformar, Cargar). **(!) Requiere conocimientos intermedios de programación.** Permite:

- Programación por componentes
- Integral datos de múltiples fuentes

2. Conversión de datos



Objetivo: adaptar el formato de los datos para facilitar su análisis.



Ejemplos de herramientas



Mr Data Converter

COMPLETAMENTE GRATUITA

- Conversión entre formatos CSV, Excel, JSON, HTM, XLM
- Interfaz web sencilla
- Sin instalación requerida



Pandoc

COMPLETAMENTE GRATUITA

- Conversión universal de documentos
- Soporta más de 20 formatos diferentes
- Línea de comandos potente



Tabula

COMPLETAMENTE GRATUITA

- Extracción de tablas desde PDF
- Convierte documentos en formatos reutilizables
- Útil para informes y documentación oficial



3. Análisis de datos



Objetivo: explorar, procesar y obtener *insights* de los conjuntos de datos.



Software de análisis amigable



WEKA

COMPLETAMENTE GRATUITA

- Aprendizaje automático y minería de datos
- Interfaz gráfica
- Integración con scikitlearn, R y Deeplearning
- Ideal para principiantes en *machine learning*



ORANGE

COMPLETAMENTE GRATUITA


- Paradigma *drag and drop* (arrastrar y soltar)
- Visualizaciones interactivas
- Análisis estadístico accesible



KNIME

GRATIS EN SU VERSIÓN BÁSICA

- Análisis de datos visual
- Flujos de trabajo mediante conexión de nodos
- Amplia biblioteca de componentes



Entornos de desarrollo



Jupyter Notebook

COMPLETAMENTE GRATUITA


- Documentos ejecutables
- Combinación de código, visualizaciones y narrativa
- Soporta múltiples lenguajes
- Ideal para reproducibilidad



RStudio

GRATIS EN SU VERSIÓN BÁSICA

- Entorno completo para lenguaje R
- Integración de consola, editor y visualización
- Herramientas estadísticas avanzadas



Lenguajes de programación para análisis de datos



R

COMPLETAMENTE GRATUITA

Especializado en estadística

- Potente para análisis estadístico y visualización
- Bibliotecas destacadas:
 - » **Tidyverse**
 - » **ggplot2**



Python


COMPLETAMENTE GRATUITA

Lenguaje versátil

- Recomendación: usar Anaconda para gestión de entornos
- Las principales bibliotecas para análisis son:
 - » **Pandas** (manipulación de datos)
 - » **NumPy** (cálculo numérico)
 - » **scikit-learn** (*machine learning*)
 - » **Matplotlib** (visualización)



Herramientas emergentes



Streamlit

COMPLETAMENTE GRATUITA


- Creación rápida de aplicaciones web de datos
- Solo requiere Python
- Prototipado veloz de *dashboards*
 - » En este [ejercicio práctico](#) lo utilizamos para crear un chat de datos públicos.



Apache Spark

COMPLETAMENTE GRATUITA

- Procesamiento distribuido
- Para *Big data*
- APIs en Python, R y Scala



Polars

COMPLETAMENTE GRATUITA

- Alto rendimiento
- Alternativa optimizada de pandas
- Procesamiento paralelo



Recomendación

Comienza con herramientas sencillas como Jupyter y Python, y gradualmente explora opciones más avanzadas según tus necesidades de análisis.

Descubre aquí los beneficios y pasos del [Análisis Exploratorio de Datos \(AED\)](#).

